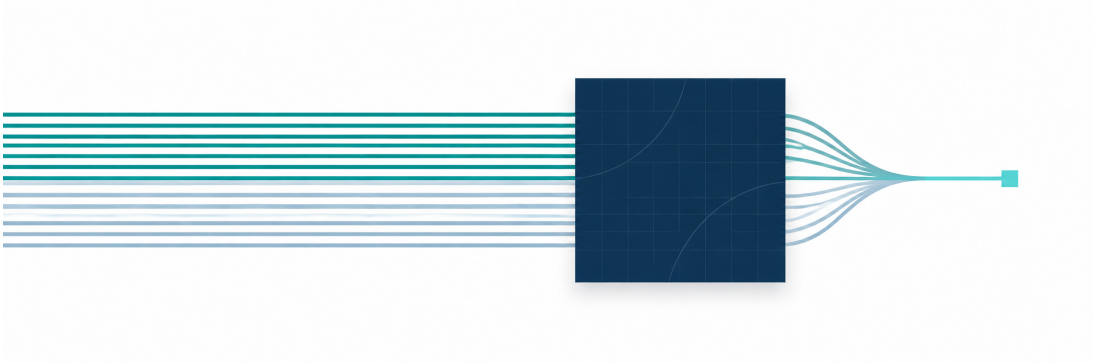
香山昆明湖 V2

自定义向量点积指令

第三阶段：协同仿真与性能评估

设计、验证与性能评估



三阶段工程技术报告

2026 年 11 月 6 日修订

目录

第三阶段：协同仿真与性能评估 **1**

3.1 从功能验证到工程评价 **1**

3.2 NEMU 参考语义与处理器接入 **2**

3.3 差分检验与错误检出 **3**

3.4 全核波形中的点积事务 **6**

3.4.1 源数据、结果与身份 6

3.4.2 从有效区间到握手边沿 6

3.4.3 输入与接受 7

3.4.4 结果与响应 8

3.4.5 提交与架构目的 9

3.5 等价 RVV 对照与测量方法 **10**

3.5.1 完整窗口与配对统计 10

3.6 硬件微基准结果 **12**

3.7 软件调用与 C8 优化 **13**

3.8 软件接入与复现说明 **15**

3.8.1 固定平台与数据布局 15

3.8.2 编译期选择与调用 16

3.8.3 从函数对象到可执行镜像 16

3.9 完整前向计算的组织与验证 **18**

3.9.1 从点积内核到模型计算链 18

3.9.2 工作量与数据布局 19

3.9.3 完整计算链的验证结果 19

3.10 综合面积、时序与设计成本 **20**

3.11 设计取舍与应用方向 **22**

3.12 评估对象与证据索引 **23**

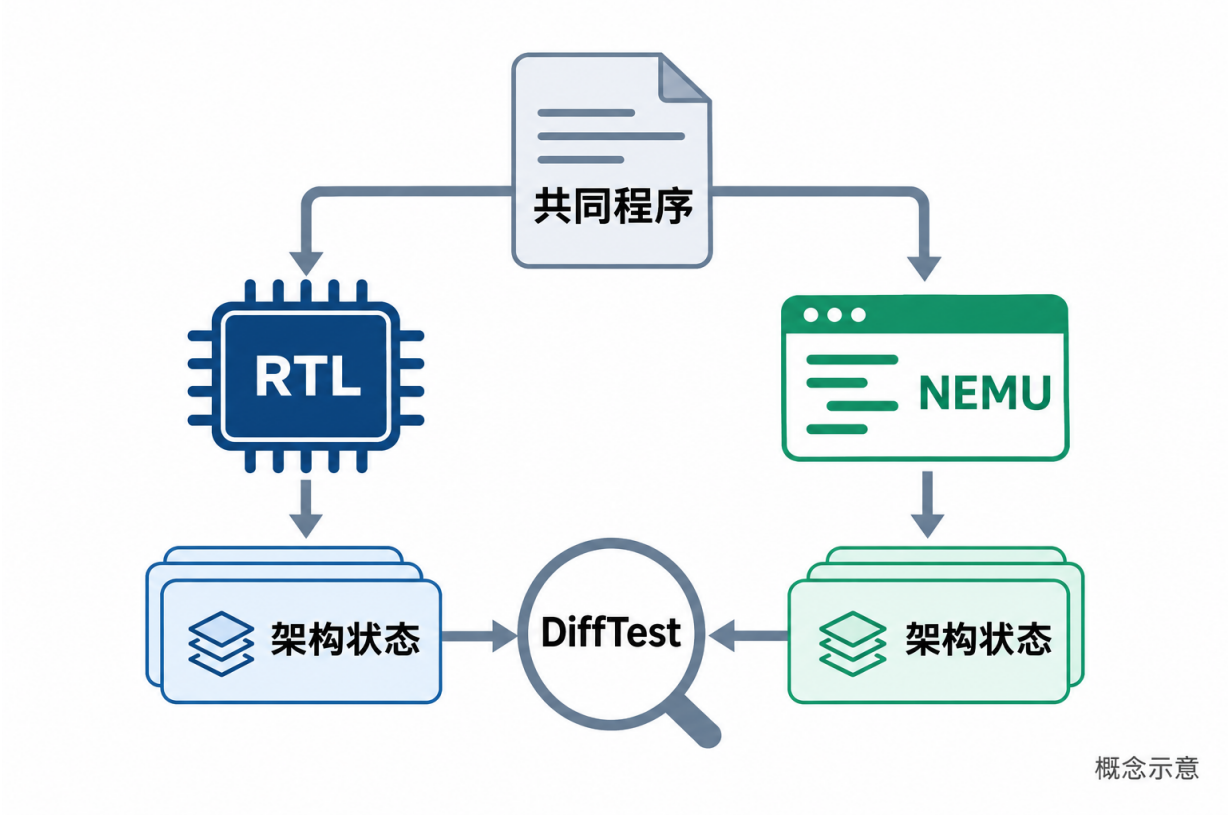
3.12.1 复现与图像来源 24

第三阶段：协同仿真与性能评估

3.1 从功能验证到工程评价

自定义指令需要在程序中产生正确结果，也需要与处理器的异常、状态和调度机制配合。本阶段使用独立 NEMU 参考模型和全核 DiffTest 核对架构行为，再以等价 RVV 程序比较完整测量窗口的周期。软件接入、综合面积和静态时序共同说明这项设计在不同场景下的收益与成本。

报告分别给出固定八项点积实现的微基准、C8 软件调用和正在推进的完整前向计算。每组结果均说明受测版本、输入与测量边界，便于从局部指令机制逐步理解其应用价值。



概念示意：独立求值与架构状态比较。技术依据见图 3-1。

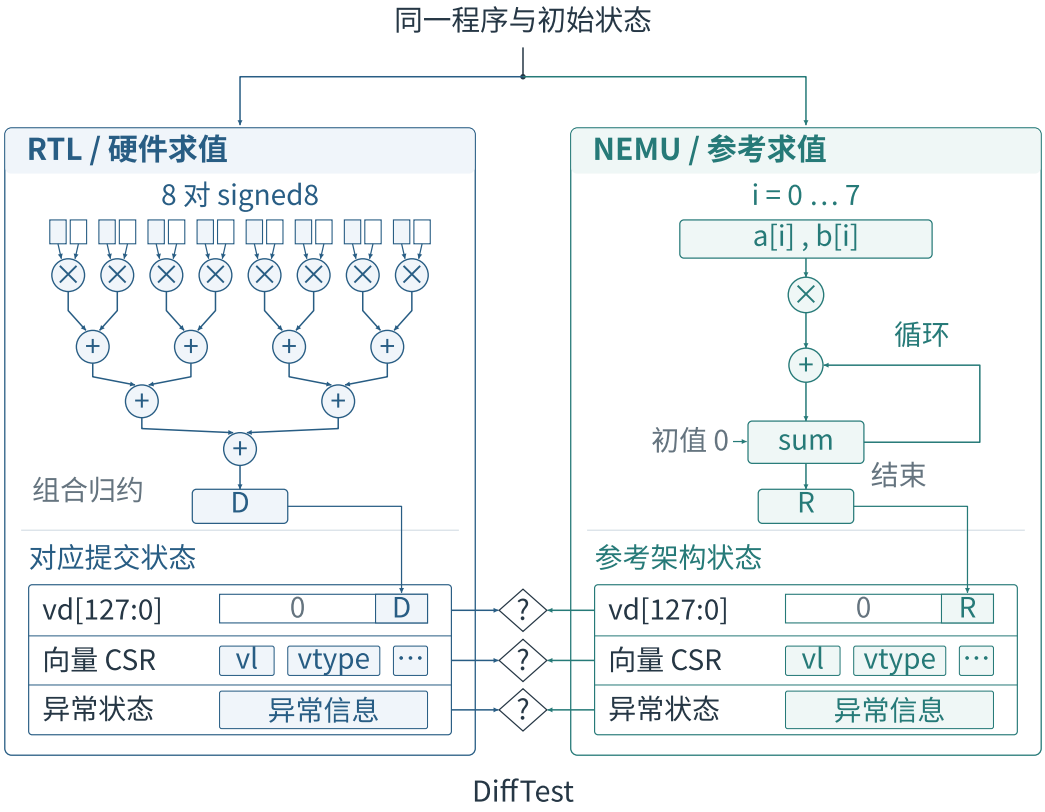


图 3-1 RTL 与独立参考模型的协同仿真

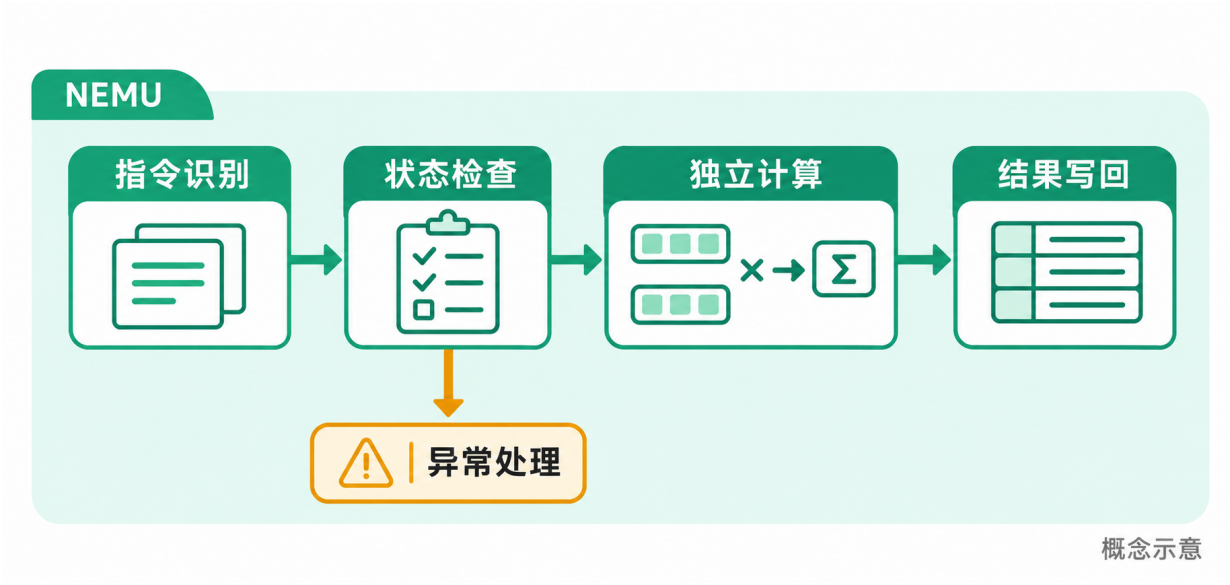
同一程序驱动香山 RTL 与 NEMU 参考模型，在架构提交边界比较向量结果，并按测试约定核对 CSR 和异常状态。

3.2 NEMU 参考语义与处理器接入

RTL 通过并行乘法、归约网络和流水状态执行点积；NEMU 参考模型则从指令字、源寄存器和向量配置出发，顺序计算八项有符号乘积之和。两个实现采用不同内部组织，对同一架构定义形成交叉核对。

参考端首先匹配 custom-0 编码并检查合法配置，随后快照读取两个源寄存器，计算点积并构造完整 128 位目的值：低 32 位为整数结果，高 96 位为零。快照读取使源、目的寄存器重合时仍使用本条指令执行前的数据。合法运算保留约定的向量状态；非法配置进入异常处理。

八项点积受测组合使用基于 NEMU 固定版本的 vdot 补丁及配套平台适配。适配依据指令和架构状态对齐该香山版本的 xTVAL 行为，异常码、陷阱 PC、xTVAL 和目的寄存器状态均保留检查。现有特权测试记录覆盖 M 模式。参考库、故障注入库与独立运行的 NEMU 各自记录构建身份，复现时按用途选择对应制品。



概念示意：识别、检查与执行。技术依据见图 3-2。

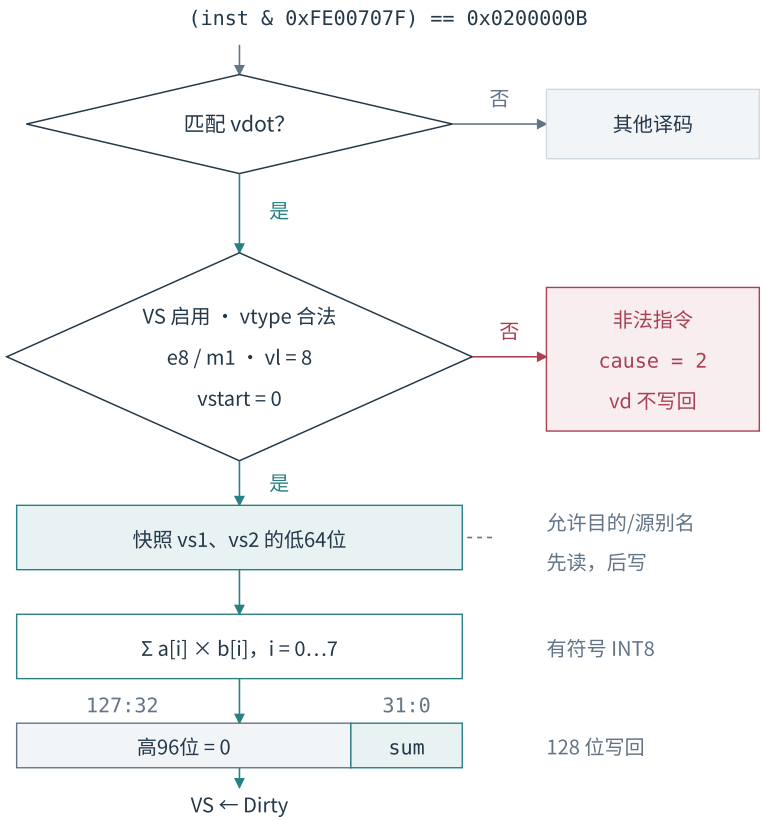


图 3-2　参考模型的译码、状态检查与完整写回

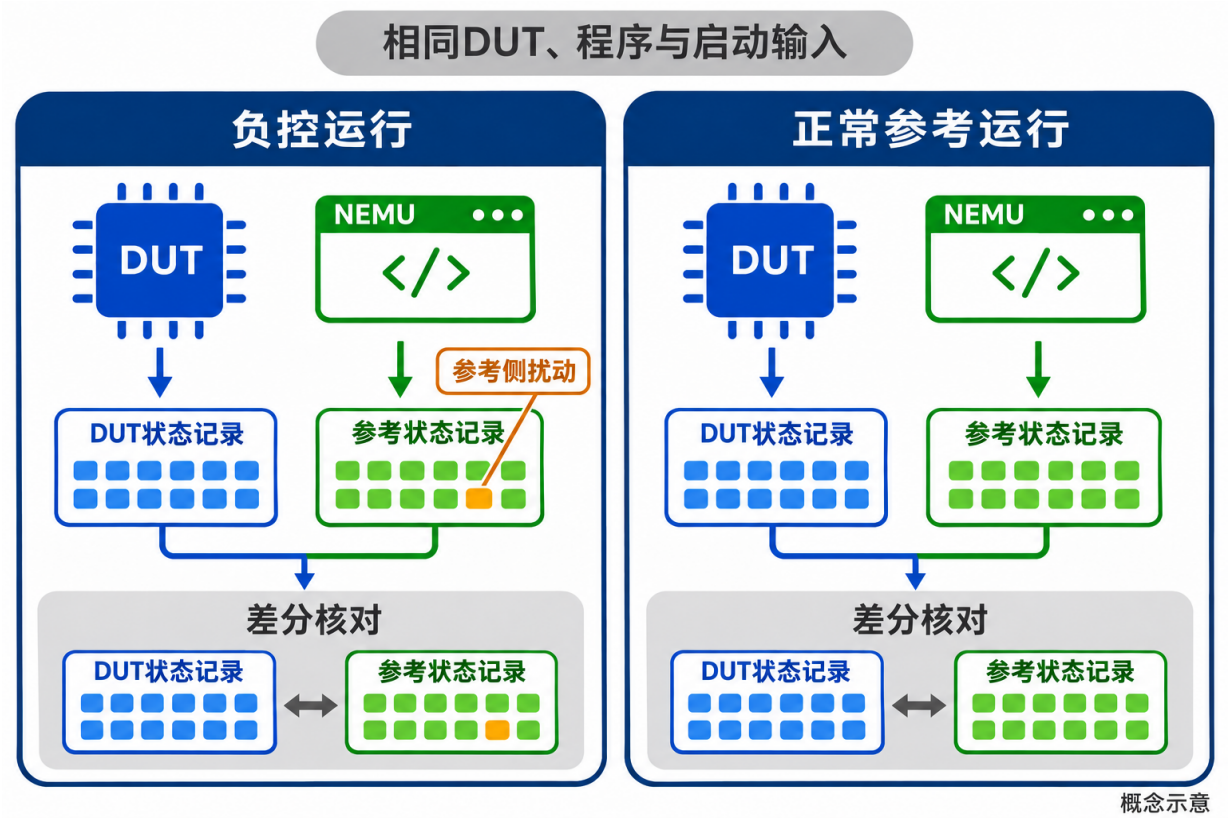
参考端先检查编码与向量状态，再快照源值、求和并写回；非法状态沿异常路径完成。平台适配与对应受测版本共同固定。

3.3　差分检验与错误检出

基础功能矩阵覆盖正数、负数、边界值、寄存器别名和非法向量配置。在八项点积两槽受测组合中，全核矩阵包含 117 个不同用例，按矩阵分片共执行 124 次；算术 RTL 的 10022 项测试和

真实父级控制测试分别承担数值与握手覆盖。R5 组合验收汇合 13 项已归档记录与 1 项新增控制诊断，并重新解析其原始输出。

为了检验完整 128 位比较是否有效，负控在参考端的 vdot 结果中翻转 bit100。差分器检测到目的寄存器高半区不一致并按预期终止；恢复正常参考模型后，同一程序完成 15 项检查并到达 GOOD TRAP。图3-3给出了这两个互补结果：前者检验错误检出能力，后者检验正常执行路径。



概念示意：扰动检查与正常参考对照。技术依据见图 3-3。

（a）参考端翻转 bit100：差分器检出高位差异

```
PS C:\Users\33532> Start-Process 'D:\sharex\ShareX\pages\2026-11\Notepad_kUWl09ct1X.png'
PS C:\Users\33532> wsl -d Ubuntu-22.04 -- tail -n 7 /home/riscv/riscv-lab/software-import-20261026/clean-02/fullcore-run-01/runs/negative-vdot/run.log
privilegeMode: 3
v10_high different at pc = 0x0080001bdc, right= 0x0000001000000000, wrong = 0x0000000000000000
Core 0: ABORT at pc = 0x800016b0
Core-0 instrCnt = 238849, cycleCnt = 311097, IPC = 0.767764
Seed=0 Guest cycle spent: 311100 (this will be different from cycleCnt if emu loads a snapshot)
Host time spent: 740557ms
PS C:\Users\33532> wsl -d Ubuntu-22.04 -- cat /home/riscv/riscv-lab/software-import-20261026/clean-02/fullcore-run-01/runs/negative-vdot/exit-code.txt
1
PS C:\Users\33532>
```

（b）恢复正常参考模型：15 项检查通过

```
PS C:\Users\33532> wsl -d Ubuntu-22.04 -- tail -n 6 /home/riscv/riscv-lab/software-import-20261026/clean-02/fullcore-run-01/runs/functional-0/run.log
VDOT_SUMMARY mode=full contract=vdot-s8x8-r32-v0.1 planned=15 executed=15 passed=15 failed=0 unreachable=0
Core 0: HIT GOOD TRAP at pc = 0x8000236a
Core-0 instrCnt = 580586, cycleCnt = 737849, IPC = 0.786863
Seed=0 Guest cycle spent: 737853 (this will be different from cycleCnt if emu loads a snapshot)
Host time spent: 1663260ms
PS C:\Users\33532> wsl -d Ubuntu-22.04 -- cat /home/riscv/riscv-lab/software-import-20261026/clean-02/fullcore-run-01/runs/functional-0/exit-code.txt
0
```

图 3-3　高位错误检出与正常参考模型恢复的原始日志

负控日志显示 `v10_high different`、ABORT 和退出码 1；差异 PC 为 `0x80001bdc`，ABORT 报告 PC 为 `0x800016b0`。其中 `right/wrong` 是比较器两侧标签，本例的扰动由参考端注入。正常日志显示 15 项全部通过、`HIT GOOD TRAP` 和退出码 0。原记录分别为 clean-02 的 `negative-vdot` 与 `functional-0`；截图及对应运行索引随源包保存。

3.4 全核波形中的点积事务

为观察点积在全核中的输入、响应和提交，2026 年 11 月 5 日使用稳定八项点积版本的 clean-02 封存生成 RTL，单独构建了支持 FST 的 EMU。1681 项生成输入与原清单一致；该模型运行原 functional-2 镜像，加载正常 NEMU 参考库并启用 DiffTest，最终到达 GOOD TRAP、退出码 0。以下波形将同一笔正数点积从执行输入关联到架构提交。

3.4.1 源数据、结果与身份

两个源寄存器均为 0xa5a5a5a5a5a5a5a50807060504030201，低八个有符号字节依次为 1 至 8。预期结果为

$$1^2 + 2^2 + \cdots + 8^2 = 204.$$

实际 128 位响应为 0x000000000000000000000000000000cc，符合低 32 位保存结果、高 96 位清零的布局。高 64 位 A5 哨兵同时检验了源元素选择范围。

关联字段	观测值
ROB 与物理目的	ROB0:39；物理目的 103（十六进制 67）
提交观察	`io_valid=1`、`io_vecwen=1`；架构目的 v10
PC 与机器字	PC=`0x80001b8c`；机器字 `0x0294050b`

3.4.2 从有效区间到握手边沿

波形中的 valid 表示一段有效区间，事务接受则发生在 valid 与 ready 同时有效的时钟上升沿。两者按下表区分，便于与日志中的周期坐标对照。

事件	显示坐标（ps）	观察依据
输入有效（A）	678694	输入 valid、ready 均为 1，源值及身份有效
输入接受边沿	678696	边沿前握手有效，边沿后 P 槽有效
输出有效（B）	678698	R 槽有效，输出 valid、ready 均为 1，结果 204
输出握手边沿	678700	边沿前输出有效，边沿后 R 槽清空
DiffTest 提交观察（C）	678710	提交有效，PC、编码、ROB 与目的相符

同一事务的 O2 日志记录接受、响应和内部 ROB 提交周期分别为 339296、339298、339301。接受到响应相隔两个全局模型周期，与第二阶段的两槽时序一致。内部 ROB 提交对应模型坐标 678706，DiffTest 观察口在 678710 有效，反映两拍观察流水延迟。分析执行时延时使用实际握手和内部提交坐标，分析 DiffTest 接口时使用其观察坐标。

图上方为全局时钟，下方为点积局部门控时钟；局部空闲时可停止时钟。显示单位 ps 是仿真模型的时间坐标，相邻全局周期相隔两个坐标单位。程序性能采用 DUT 周期，物理时序由综合和 STA 评估。

以下三幅 GTKWave 截图分别展示输入、响应和提交。截图保留信号值，仅裁去层级栏和外部空白；完整原图、事务采样、运行回执与文件摘要见 evidence/vdot-wave-20261105/和 figures/source-screenshots/。

3.4.3 输入与接受

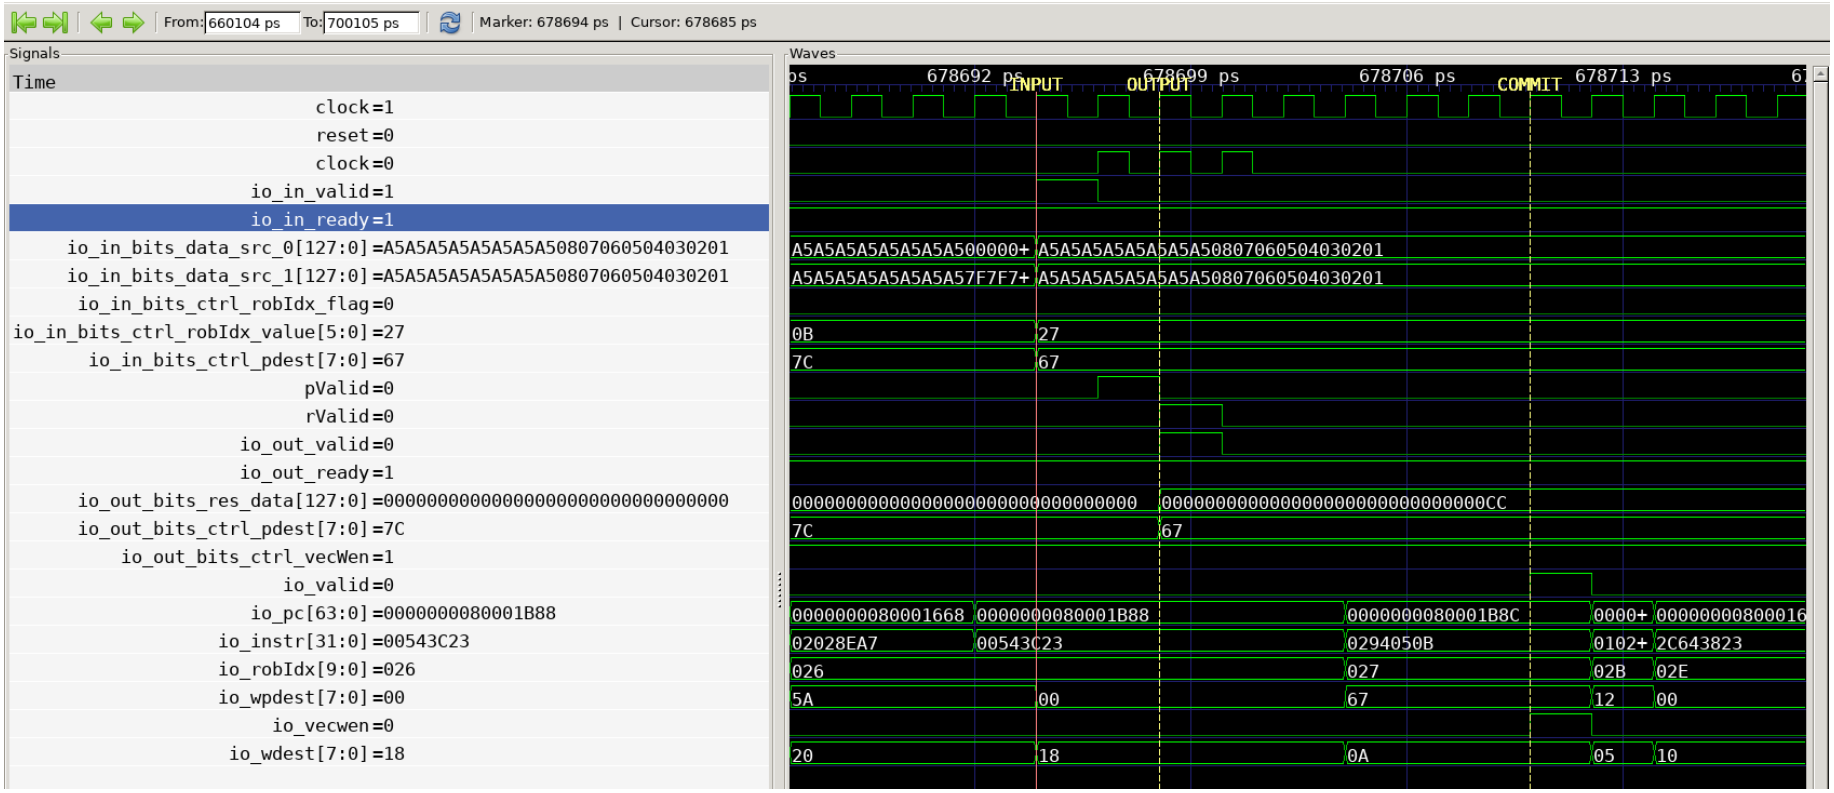


图 3-4　正数点积的输入与接受边沿

游标 678694 处输入 valid、ready 为 1；源低八字节为 1 至 8，ROB 值 27 和物理目的 67 按十六进制显示。678696 上升沿接收请求，P 槽有效。

3.4.4 结果与响应

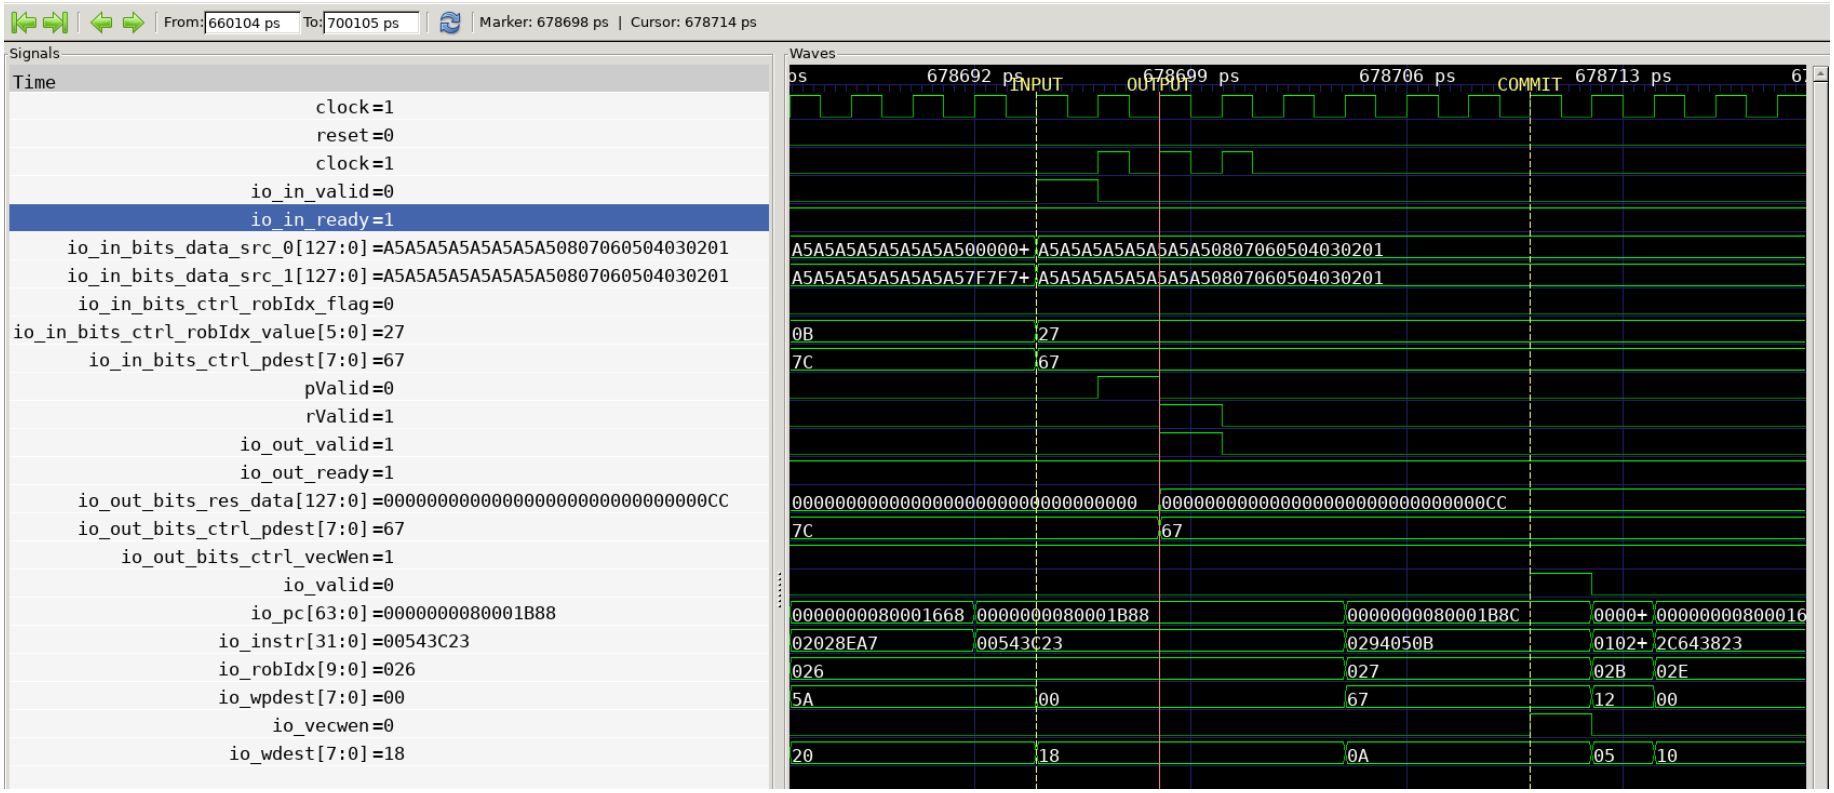


图 3-5　完整 128 位结果与响应握手

游标 678698 处 R 槽及输出 valid、ready 有效，结果为 204 且高 96 位为零；678700 边沿完成握手并释放 R 槽。此时提交观察口 io_valid 为 0。

3.4.5 提交与架构目的

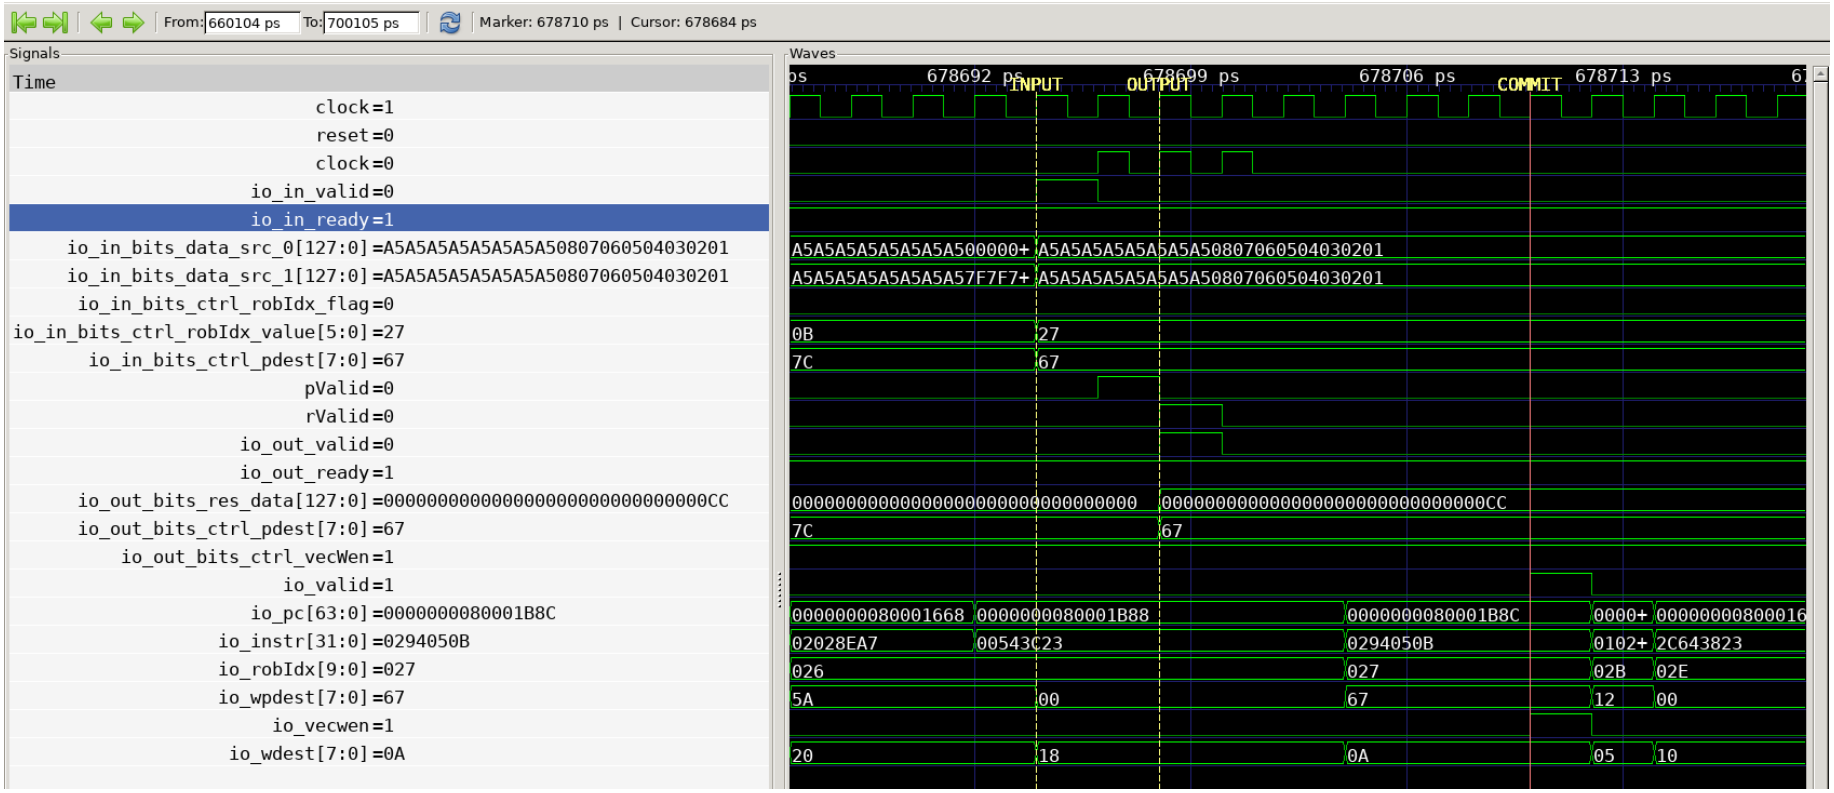


图 3-6 DiffTest 提交观察与架构目的

游标 678710 处提交有效，PC80001B8C、机器字 0294050B、ROB027、物理目的 67、架构目的 0A（v10）及向量写使能对应同一事务。观察口的两拍流水延迟已在正文对齐。

3.5 等价 RVV 对照与测量方法

8 项点积微基准中的标准 RVV 对照，通过宽乘和宽归约计算与 VDot 相同的有符号点积。单次已知配置序列先以 `vwmul.vv` 得到 16 位乘积，再切换到 `e16/m1/VL8`，清零整个目的寄存器并执行 `vwredsum.vs`，最后恢复入口配置。高 96 位在归约过程中保留为零，低 32 位保存完整整数和。

该微基准按使用场景组织：已知配置的单次点积为 5 条主体指令，通用入口增加 `vl/vtype` 保存，共 7 条；四个独立点积共享配置切换，主体合计 14 条。批处理中的配置复用使标准 RVV 也能充分利用独立计算，而比较仍覆盖双方实际执行的清零、搬运和状态管理。

3.5.1 完整窗口与配对统计

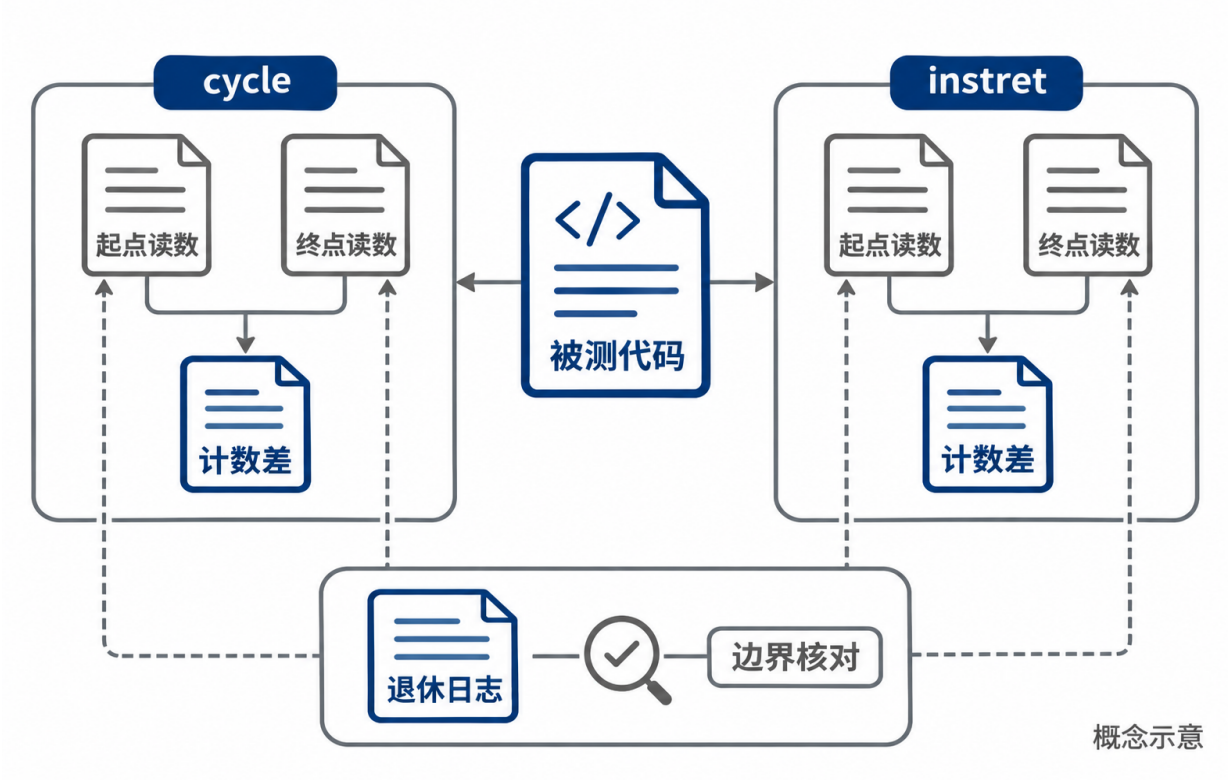
测量采用同一输入、循环次数、镜像配置和边界规则。每个微基准场景使用三组数据，每组统计四个正式窗口；首次、预热和独立重放分别保存。计时保留实际执行的配置切换、循环与边界开销，统计单位为 DUT 全局周期。

香山是乱序处理器，计数器的读取时刻需要与指令执行位置对应。项目在固定受测实现上组合使用 fence 与 cycle、instret 读数，并通过观察器关联四条 CSR 指令的 PC、机器字、ROB 身份、采样和退休事件。cycle 差与全核采样 tick 差相符，instret 差与退休记录及 ELF 展开计数相符；绝对计数器使用整数解析。该方法的适用对象由受测硬件和测量合同共同确定。

加速比与周期降低率分别定义为

$$S = \frac{C_{\mathrm{RVV}}}{C_{\mathrm{VDot}}}, \qquad R = \frac{C_{\mathrm{old}} - C_{\mathrm{new}}}{C_{\mathrm{old}}}.$$

二者使用不同分母，表中同时给出原始周期与比较对象。完整窗口还包含调度、访存、循环和边界开销，因此与第二阶段的 FU 两拍最早响应分别报告。



概念示意：测量窗口与执行边界。技术依据见图 3-7。

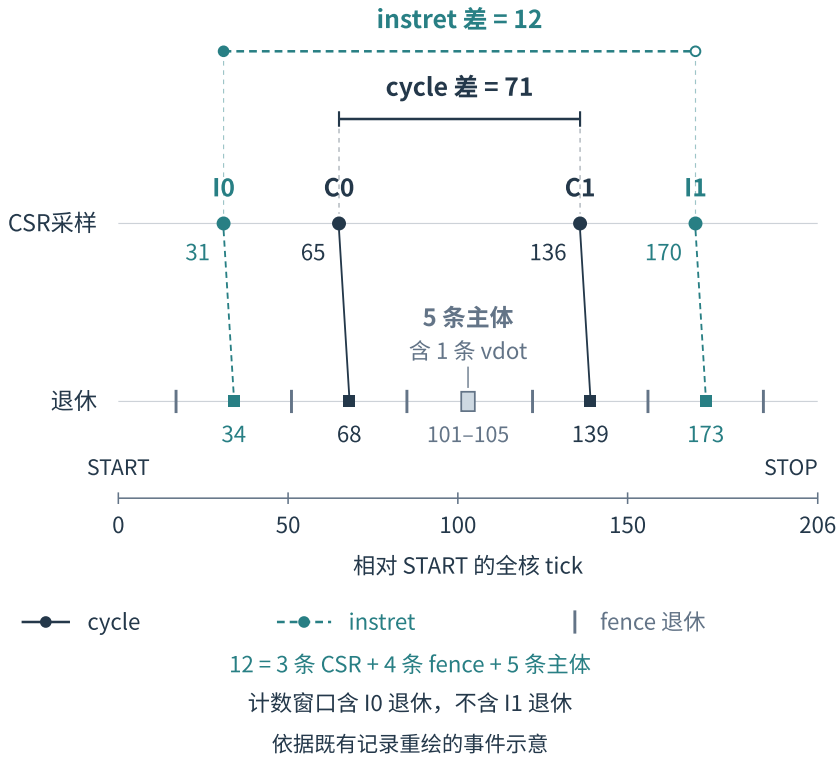


图 3-7　CSR 采样、退休与计时窗口的对应关系

依据观察器事件重绘。所示窗口的 cycle 差为 71、instret 差为 12；图中分别标出进入 ROB、CSR 采样与退休事件。

3.6 硬件微基准结果

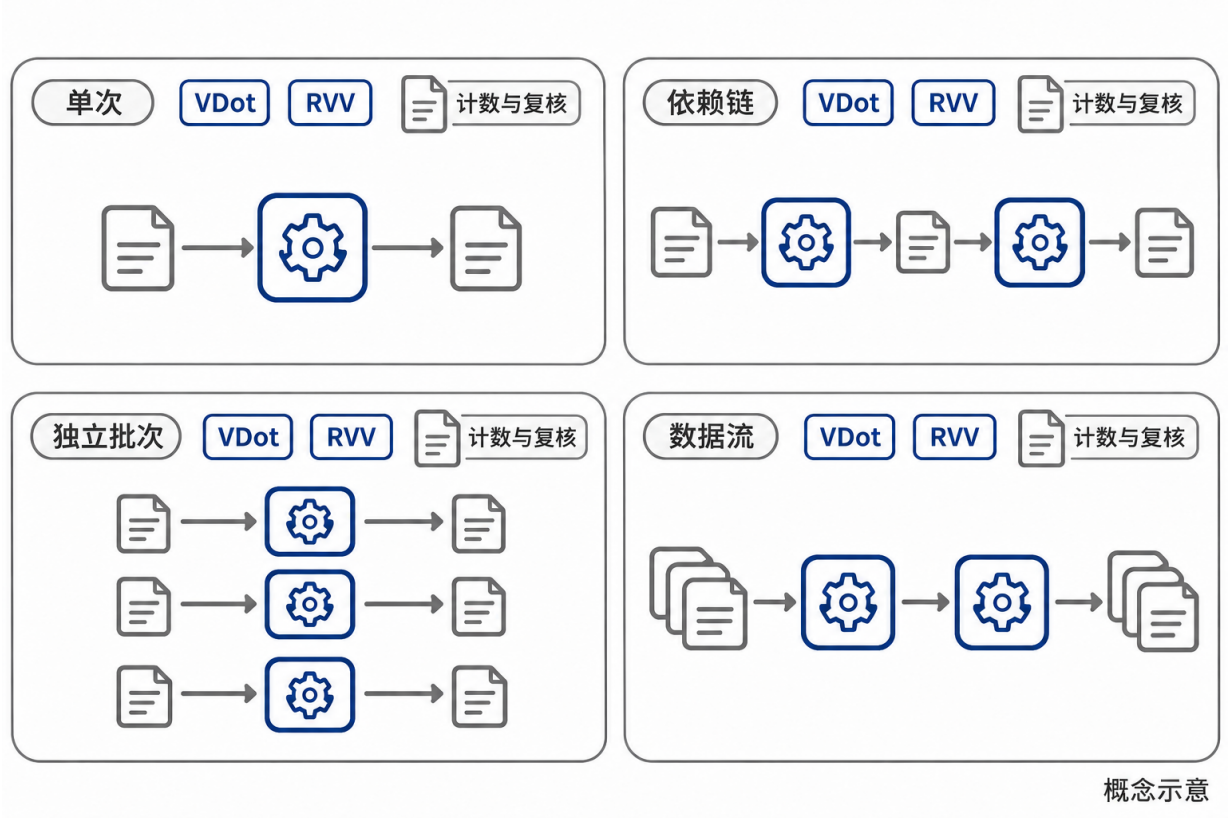
四类微基准分别观察单次点积、连续数据依赖、独立任务吞吐，以及加载、计算与存储共同作用下的表现。表 3-3 使用同镜像中的 VDot 与等价 RVV 路径；每个场景、每种实现使用三个数据集，每个数据集取四个正式窗口，共十二窗。

表 3-3 0f 受测实现的微基准结果（周期均值）

场景	VDot	RVV	加速比
单次点积	71.00	85.25	1.2007×
依赖链（256 次）	1,857.00	5,440.50	2.9297×
四路独立批量（128 次）	221.00	678.00	3.0679×
加载、计算、存储流（64 次）	1,127.50	1,133.00	1.0049×

加速比按同一场景的 RVV 周期总和除以 VDot 周期总和计算。独立批量由 32 轮四路点积组成，能够持续向流水线提供相互独立的工作；依赖链则要求每次点积使用前次结果。两者分别呈现了吞吐率和依赖关系对收益的影响。加入加载、存储与循环控制后，stream64 两条路径的周期接近，说明仅缩短整数点积还不足以决定整个计算循环的速度。

在单独的 O1 与 O2 同镜像比较中，独立批量由 362.5 周期降至 221 周期，减少 39.03%。在 0f 与其修复前版本的独立复核中，对同一实现、同一输入、同一序号的 96 对正式窗口进行比较，周期差值均为零。这些结果提示，应用优化还需同时考察任务独立性、数据搬运和循环开销。



概念示意：统一条件下的性能比较。技术依据见图 3-8。

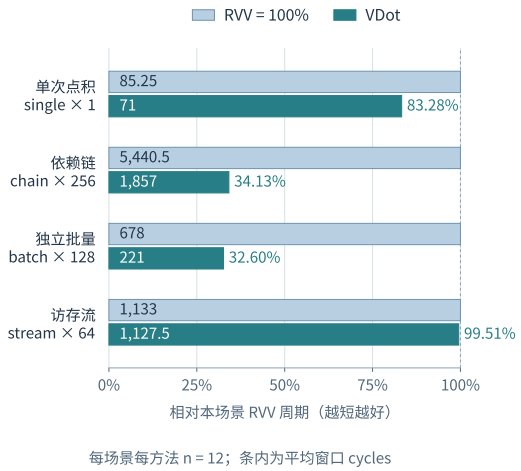


图 3-8 四类微基准周期与 RVV 归一化结果

每个场景以 RVV 周期为 100%；条内列正式窗口的平均 DUT 周期，条尾列 VDot/RVV 周期百分比。加速比见本节表格。

3.7 软件调用与 C8 优化

前述微基准考察 8 项点积的指令序列，本节转向 8 行、每行 32 项 GEMV 的完整函数调用。硬件点积单元要在矩阵运算中发挥作用，还需要减少相邻计算之间的配置和数据搬运。firstdot 用首段点积直接初始化累加状态，随后接续其余分段；C8 在复用输入向量的 8 行、每行 32 项 GEMV 路径中，进一步消除重复的向量配置。两者分别减少累加初始化与配置管理的开销。

C8 提供普通 RV64 C 接口。调用者将行优先矩阵 $A[8][32]$ 和输入向量 $x[32]$ 连续存放，形成 288 字节输入；返回值写入 8 个 16 字节结果槽，每槽低 32 位保存 INT32 点积，高 96 位清零。固定槽布局与指令的完整结果格式一致，便于在功能检查和后续处理之间传递结果。

VDot 路径将每行分为四个 8 项点积段；RVV 路径则处理两个 16 项半组，以 `e8/m1/VL16` 宽乘和 `e16/m2/VL16` 宽归约接续得到完整 32 项组和。两种实现共享输入布局与完整结果格式，各自采用适合的分组和配置复用方式。

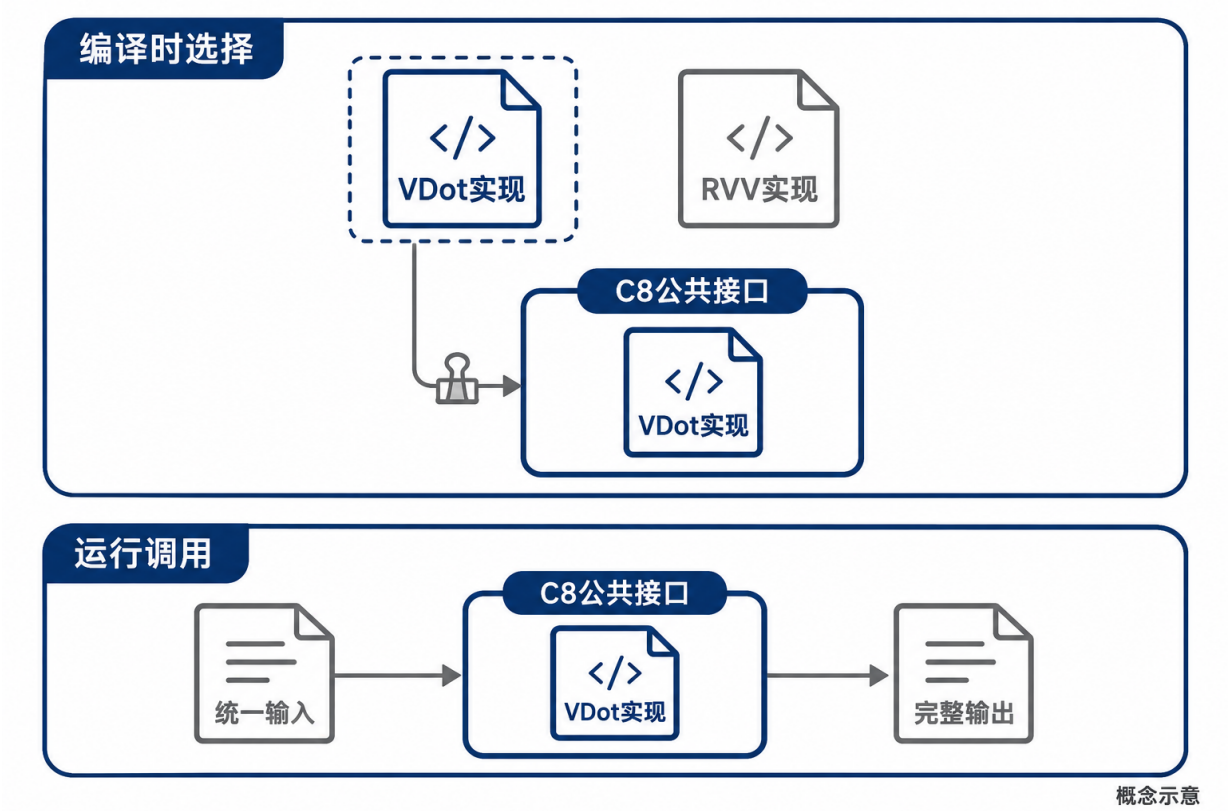
8×32 整数 GEMV 调用	周期均值	对照意义
firstdot	282.25	首段直接初始化
C8 配置复用 VDot	273.00	本节选用实现
同批较快合格 RVV	299.00	标准指令对照

在稳定八项两槽实现的这组 8×32 配对测量中，输入已打包为 INT8，输出为 8 个完整结果槽。C8 相对 firstdot 减少 3.2772% 的周期，相对较快 RVV 的加速比为 1.095238。统计采用三个数据集、每组四个正式窗口，包含完整调用开销。这些结果说明，整数点积之外的软件组织仍然影响最终收益。[1]

接入时，`xs_c8_gemv_8x32` 在编译期选择对应函数，显式 RVV 入口提供同接口对照。原合格程序、源码复制对照和 SDK 接入版的 31,440 字节 BIN 逐字节一致，装载段、48 项调用表和

[1] C8 接口和结果见C8 软件包验收结果及其固定输入清单。这里的周期对应该 8×32 调用计划。

12 组输入也一致。[2]这条从函数对象到最终镜像的核查链，使接口封装与实际执行代码建立了明确对应关系。新应用可据此复用固定函数，并针对自己的准备流程和调用窗口开展整体验证。



概念示意：公共接口与缓冲区组织。技术依据见图 3-9。

[2]三方最终镜像比较见C8 最终镜像等价结果。

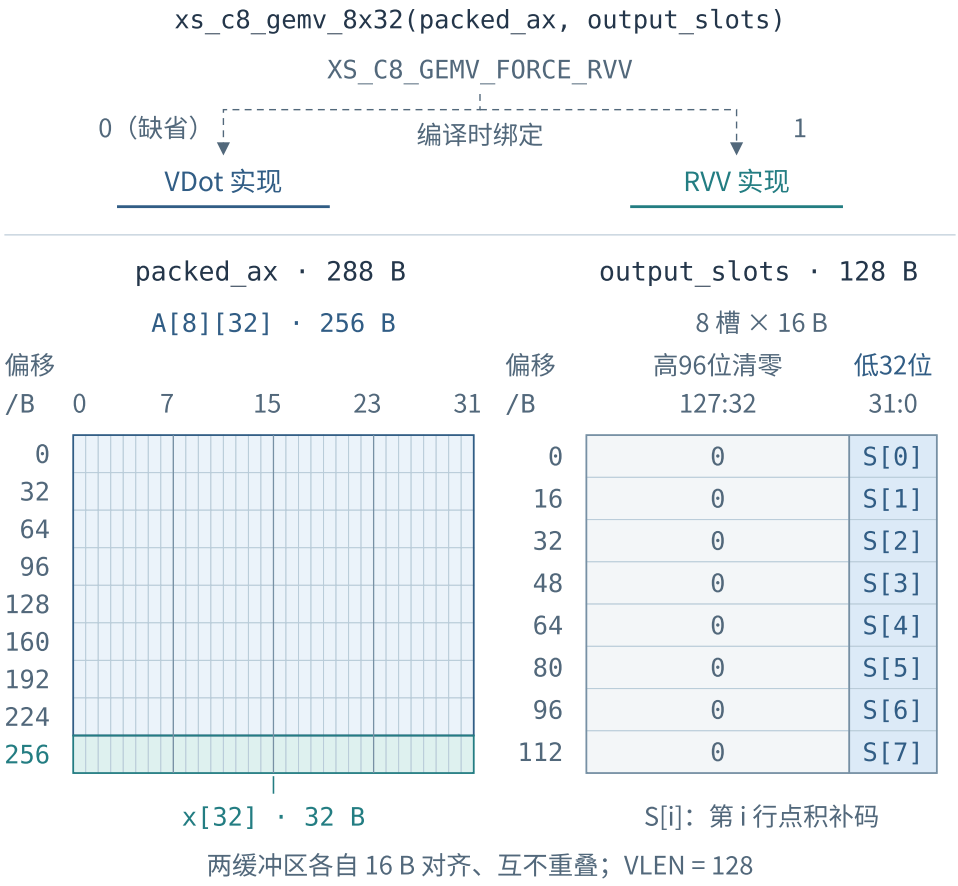


图 3-9 firstdot 与 C8 的软件入口和结果布局

C8 读取连续的 INT8 矩阵与向量，输出 8 个完整 128 位结果槽。编译期入口分别连接 VDot 或 RVV 函数，调用者使用同一缓冲区布局。

3.8 软件接入与复现说明

3.8.1 固定平台与数据布局

C8 软件包面向本项目已验证的 RV64、lp64d、VLEN128 裸机环境，调用前启用向量状态。VDot 路径使用项目的自定义点积编码；RVV 路径使用标准向量指令。输入、输出各按 16 字节对齐并独立存放，输入在调用期间保持有效。

项目	接口约定
输入	行优先 $A[8][32]$ 后接 $x[32]$，共 288 字节
输出	8 个 16 字节槽，共 128 字节
单槽	低 32 位 INT32 结果，高 96 位零
返回向量配置	`vl=8, vtype=0, vstart=0, vcsr=7`

函数沿用普通 RV64 C ABI 保存栈和被调用者保存寄存器。向量寄存器按该接口供计算使用，返回配置固定为 `e8/m1/tu/mu`。结果槽宽度对应 VLEN128 下的整寄存器存储，因此调用方按照 16 字节步长读取各行结果。

3.8.2 编译期选择与调用

头文件 selected_gemv_c8.h 提供两个入口。xs_c8_gemv_8x32 默认连接配置复用 VDot；将 XS_C8_GEMV_FORCE_RVV 设为字面量 1 后，该名称连接 RVV 实现。xs_c8_gemv_8x32_rvv 始终连接 RVV。开关为 0 或 1，选择过程在预处理阶段完成。切换版本或开关后，重新编译相关翻译单元并链接匹配的静态库。

```
#include <stdint.h>
#include "selected_gemv_c8.h"

struct c8_slot {
    int32_t value;
    uint32_t upper_zero[3];
};
static _Alignas(16) int8_t packed_ax[288];
static _Alignas(16) struct c8_slot result[8];

/* Fill packed_ax with A[8][32] followed by x[32]. */
void run_c8(void) {
    xs_c8_gemv_8x32(packed_ax, result);
}
```

需要标准 RVV 对照时，可在同一调用位置使用显式 RVV 入口。保留 firstdot 版本的应用继续使用其对应头文件和库；C8 以独立名称加入软件包，便于按具体形状选择和回退。[3]

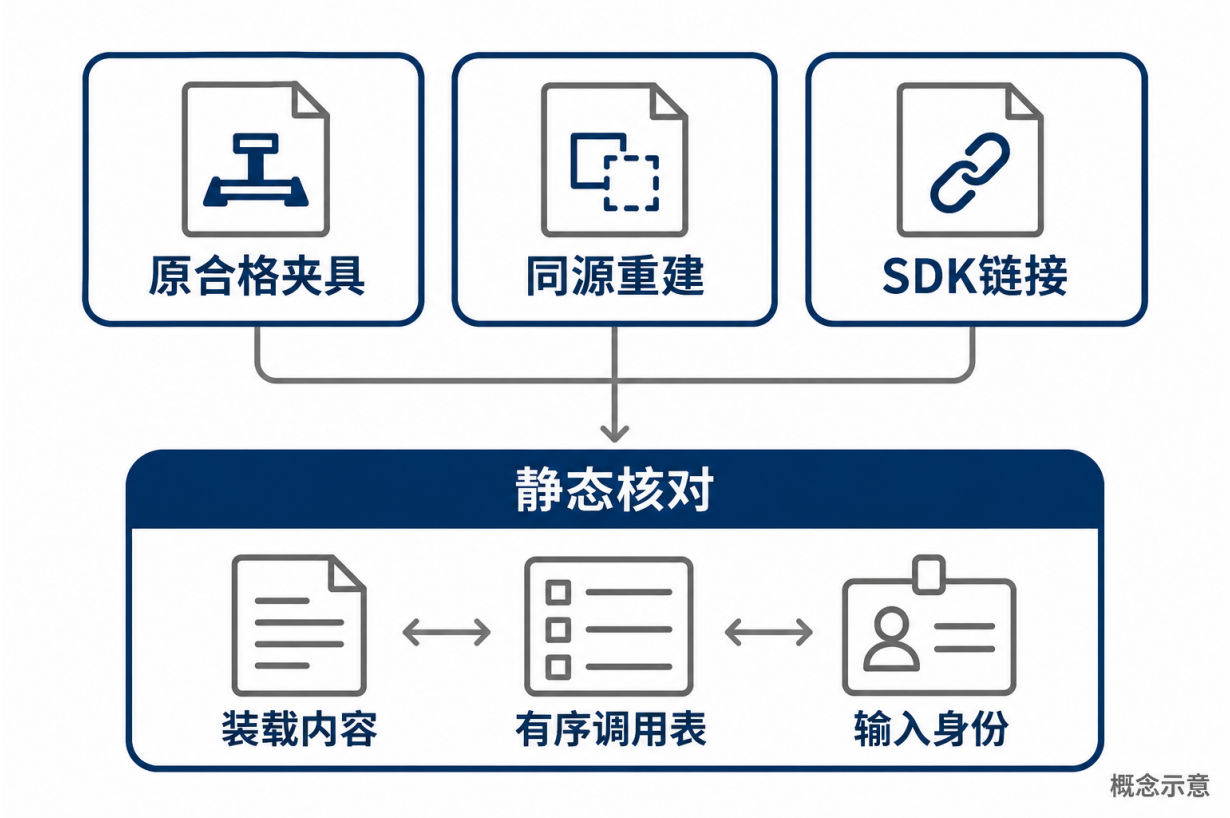
3.8.3 从函数对象到可执行镜像

软件包保留一个完整 gemv.o，由 libxs_gemv_c8.a 提供 16 个公共函数。固定 GNU 参数为-march=rv64gcv -mabi=lp64d -mno-relax。验证分别核对编译期别名、实际调用重定位、库成员抽取和最终装载内容，使每个公开入口都能追溯到被测试的函数。

SDK 接入的三方比较覆盖 BIN、PT_LOAD、BSS、函数地址与机器码、调用表及输入数据。三份 BIN 均为 31,440 字节且内容一致；去除调试节后的 ELF 也逐字节一致。源目录和头文件路径造成的调试信息差异单独保留。这使队友既能使用调试材料，又能核实接入前后的运行内容。[4]

[3]头文件及对齐示例见C8 编译期入口与同目录 example.c。接口细节见C8 合同。

[4]完整比较记录、链接映射及独立 GNU 复核见C8 最终镜像等价结果。



概念示意：三种制品分别核对装载内容、有序调用表和输入身份。技术依据见图 3-10。



图 3-10　C8 接口、静态库与最终镜像的核对流程

从头文件选择进入实际库成员，再比较最终装载段、调用记录及输入数据。三方对照连接了公开接口与已验证程序的运行内容。

复现时使用软件包的 README、固定输入清单及其配套核验工具，在独立输出目录保留构建结果。新的应用接入把模型准备、数据打包和计时窗口一并列入验证计划，按同一数据生命周期比较 VDot 与较快的 RVV 实现。

3.9　完整前向计算的组织与验证

3.9.1　从点积内核到模型计算链

应用验证将量化矩阵向量乘接入一个六层 Transformer 的完整 forward。固定合成模型的模型维度为 288，前馈中间维度为 768，注意力头数为 6，词表大小为 32,000；测试在规定初始化后，执行 token=1、position=0 的一次前向计算。权重与尺度预先完成打包，该准备成本不计入本次窗口。计数窗口包围一次完整 forward 调用，包含激活量化；计算依次经过嵌入读取、各层归一化、Q/K/V 投影、位置编码、注意力、输出投影及前馈网络，最终生成 32,000 项分类器输出。

本节的量化 GEMV 内核按每 32 项一组计算，直接生成 FP32 行输出。每组先求精确的 INT32 点积，再转换为 FP32，依次乘以权重尺度和激活尺度，最后按组号顺序累加到输出。不同内核共用权重、尺度数组及这一浮点计算顺序。Q、K、V 投影复用同一份量化激活，前馈网络的两个输入投影也共享量化结果。

3.9.2 工作量与数据布局

表 3-4 列出一次 forward 中的 43 个量化 GEMV。这里以一项乘加记一个 MAC，统计矩阵的有效维度；注意力、归一化、激活函数等运算另由完整 forward 承担。

表 3-4 固定模型一次 forward 的量化 GEMV 工作量

矩阵类别	数量	每个矩阵的形状	逻辑 MAC	占比
Q/K/V/O 投影	24	288×288	1,990,656	13.11%
前馈 W1/W3	12	768×288	2,654,208	17.48%
前馈 W2	6	288×768	1,327,104	8.74%
分类器	1	$32,000 \times 288$	9,216,000	60.68%
合计	43	—	15,187,968	100.00%

分类器占逻辑 MAC 的 60.68%，因此大矩阵路径是有价值的优化对象。这个比例描述乘加工作量；其实际耗时还取决于访存、尺度处理、循环控制及处理器执行资源。

现有布局将权重按八行和量化组打包，尺度沿每个输出行连续存放。输入维度为 288 的矩阵由 288 行面板处理，共调用 172 个面板；输入维度为 768 的六个 W2 矩阵使用对应内核。末面板保持相同计算形状，再复制有效输出。这种统一组织多计算 1,408 个填充行，使实际整数乘加项为 15,593,472，比有效工作量多 2.67%。

3.9.3 完整计算链的验证结果

固定模型已分别通过标准 RVV 路径 FR 和自定义 VDot 路径 TA 的目标机完整 forward 验证。两路均完成 3,691,424 字节的全状态比较，并核对输出保护区、调用状态及浮点异常标志。表 3-5 记录该正确性实验中各一次预设初始状态下的计数窗口；TA 独立重放得到相同的完整验证结果和窗口计数。

表 3-5 完整 forward 正确性实验中的单窗口目标机观测

实现	周期数	退休指令数
FR：标准 RVV	20,258,039	7,502,872
TA：自定义 VDot	19,774,245	10,122,100

这组观测将量化 GEMV 与其余模型运算放入同一条计算链，也显示退休指令数和周期数应分别分析。这些单窗口记录用于完整执行与复现检查，稳定的应用性能比较还需进一步测量。

在相同模型与共同程序上，进一步接入了两种标准 RVV 软件组织：GS32 一次处理完整的 32 项量化组；paired16 把前后半组对应的乘积在 16 个 INT16 通道中相加，再扩宽归约。paired16 在入口检查激活值，遇到 -128 时执行完整 FR 路径，保持完整的 signed-int8 数值域。这些入口检测和回退属于实际调用的一部分。

新生成的三路共同程序已完成 NEMU 参考验证，三个正常方法的完整输出与状态逐位一致。表 3-6 给出该组参考执行的窗口退休指令数；其中 W2 保持 FR，实现差异集中在输入维度为 288

的矩阵路径。参考指令数用于评估软件组织；该组香山目标机周期结果尚待完成验证。

表 3-6 共同参考模型中的完整 forward 指令数

实现	窗口退休指令数	相对本组 FR 的指令数减少
FR	7,502,886	—
GS32	4,828,788	35.64%
paired16	5,175,371	31.02%

共同验证还包含 paired16 重放与末项输出扰动负控，分别检查结果复现和比较器的拒错能力。

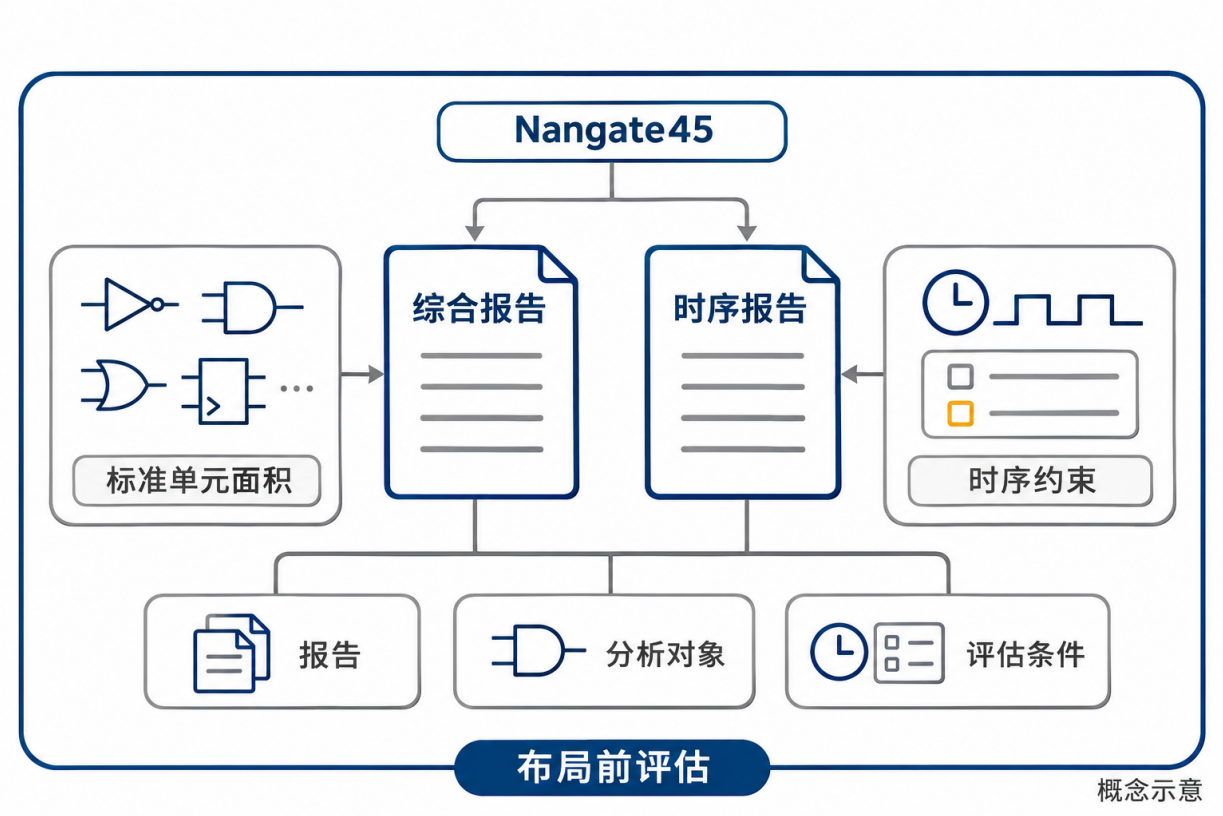
3.10 综合面积、时序与设计成本

设计成本使用 Nangate45 Typical 库，条件为 1.10V、25 °C，工具为 Yosys 0.9、ABC 1.01 和 OpenSTA 2.0.17。受测对象是带 32 位结果保存和 DIV 取消修复的八项点积两槽版本。主档采用 1 ns 时钟周期、5 fF 负载及固定线负载模型，另以 0.5 ns、2 ns 周期和 1 fF、20 fF 负载检查敏感性。

指标	独立 VDot FU	共享 VFEX4 父级
标准单元面积（μm^2）	17298.246	284614.946
寄存器至寄存器到达时间（ns）	1.163404	3.261218
该类路径 setup 裕量（ns）	−0.240117	−2.341112
所报告路径最差 setup 裕量（i2r，ns）	−0.268520	−2.393998

两个统计范围具有包含关系：VFEX4 覆盖 VDot、DIV/SQRT 及共享控制。最差 setup 裕量来自输入至寄存器路径，与表中的寄存器至寄存器路径分别列示。1 ns 主档下两种统计范围均存在 setup 违例，后续物理实现需要继续进行时序收敛；本组映射和 STA 数据用于比较相同工艺与约束下的结构成本。

将结果状态从 128 位收窄为 32 位后，独立 FU 面积相对其前一版减少 2.33386%，共享父级减少 0.137349%。进一步加入 DIV 取消修复时，独立 FU 面积保持 17298.246 μm^2，父级由 284879.882 降至 284614.946 μm^2；对应 96 对正式微基准窗口的周期逐对相同。控制正确性、面积和各类时序路径共同支持设计取舍。



概念示意：面积与时序的不同约束。技术依据见图 3-11。

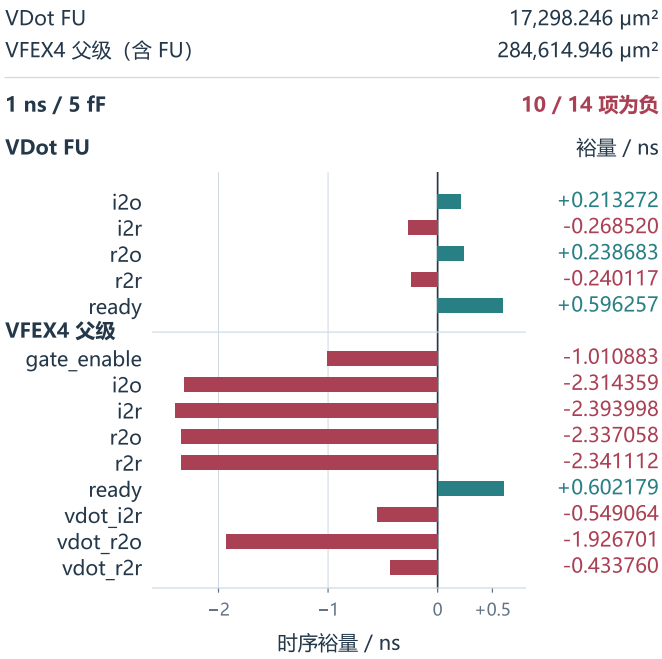


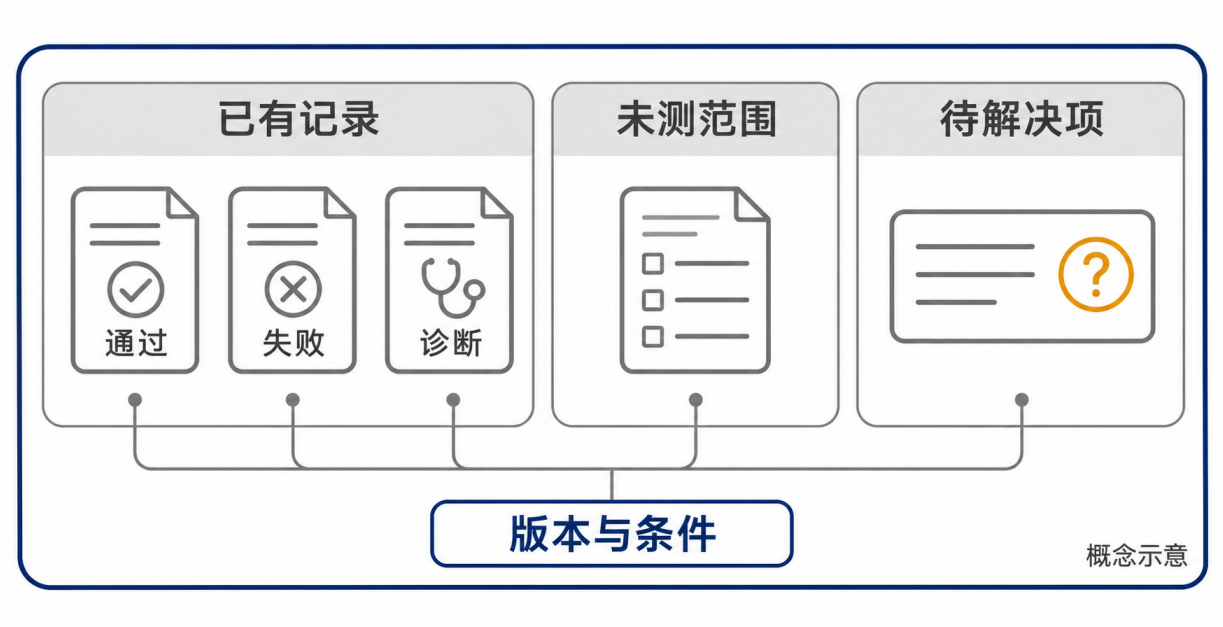
图 3-11 Nangate45 模块面积与主档 STA 裕量

主档采用 1ns 周期、5fF 负载。图中列出 FU 和包含 FU 的完整 VFEX4 父级面积，以及 14 类路径的 setup 裕量，其中 10 类为负值。

3.11 设计取舍与应用方向

两槽流水改善独立点积的持续供给，32 位结果保存利用了指令布局中的常零高位，DIV 取消修复完善共享资源的释放。软件侧则通过 firstdot 初始化、C8 配置复用及更适合量化组的 RVV 组织减少实际调用开销。各项优化作用在不同环节，配对实验使其收益与代价能够分别解释。

固定 GEMV 已经给出普通 C 调用的周期结果，完整前向计算进一步验证了量化内核与模型计算链的衔接。最新十六项点积候选完成了指令和执行通路的功能验证，后续应用比较将继续保留较快的标准 RVV 对照。布局后时序、整核频率和功耗则属于进一步物理实现的评价内容。



概念示意：已知证据与尚未覆盖的边界。技术依据见图 3-12。

八项点积受测组合 0f + firstdot V2 + C8

● 已有记录　○ 待评估　— 随所属硬件评估

证据层级	逻辑与执行		物理实现		
	功能正确性	周期观察	单元面积	布局前 STA	功耗
局部 VDot FU 算术与握手	●	●	●	●	○
VFEX4 父级 含 FU 与 DIV	●	●	●	●	○
整核程序 差分／微基准	●	●	○	○	○
固定 GEMV / C8 完整调用	●	●	—	—	—

周期单位	FU 握手拍；整核与 C8 为 DUT 周期
功能记录	全核 117 用例／124 次；C8 最终镜像等价
时序结果	1 ns／5 fF：14 类中 10 类 setup 裕量为负
后续评估	整核 Fmax、布线后时序与功耗
复现方式	固定源码、镜像、输入及配套原始记录

图 3-12　八项点积受测组合的验证与评估范围

实心点表示该对象已有对应记录，包含未收敛的 STA 结果；空心点标出后续评估项目。FU 的局部握手拍与整核、C8 的 DUT 周期分别计量。

(a) FU/parent and full-core scope: evidence column of R5 matrix

0f真实FU与VFEX4父级；完整128位、反压/取消/身份/异常、严格DIV关钟及4+16负控；复用0f原167载荷；未新执行RTL仿真，不转授C1/C2/C3
固定原13项重新解析+新o2-control-diagnostic；117不同/124次功能例，O2覆盖及负控恢复；组合验收不是fresh14；原14项UTC容量FAIL保留；本次UTC间隔比单调时钟短62.888356秒，系统墙钟稳定性未证实，新占用审计采用单调包络

(b) Cost scope: evidence column of R5 matrix

0f同约束面积/五档STA资料1008文件回读；FU17298.246、父级284614.946微米平方；不是新综合；1ns负slack保留，整核Fmax/布线后时序/功耗NOT_TESTED

图 3-13　八项点积受测组合的验收与成本记录摘录

上部列出 FU、父级及整核功能记录；下部列出标准单元面积和布局前 STA 的评估范围。对应结果在本章按测试对象和指标分别说明。

3.12　评估对象与证据索引

报告按实际受测对象组织结果。四类微基准、普通 C 调用和完整 forward 各自对应固定的代码、程序与输入；可沿下列索引定位产生每组结果的实验。

评估对象	固定身份	对应结果
0f 硬件微基准	硬件提交 `0f12df6753` 及该批冻结 EMU	四类微基准的正式窗口和同镜像比较
R5 工程复现	`clean-02` 构建及其参考模型	干净环境构建、差分和工程验收
C8 普通 C 入口	最终 BIN 的 SHA256 前缀 `56805506eb98`	固定 GEMV、调用状态与最终镜像等价
FR/TA 完整 forward	固定 T17 环境与 FR/TA 消费者程序	首个 token 完整执行、全状态比较及目标机单窗口观测
三路 RVV 完整 forward	共同 FR/GS32/paired16 程序及固定模型	全状态比较、重放、负控及参考指令数

四类微基准可由微基准原始窗口 CSV与测量方法与成本汇总复查；软件包的使用与版本选择见C 入口与版本间比较。

完整前向计算的FR/TA 目标机记录和FR/GS32/paired16 共同参考结果分别保存目标周期与参考指令计数。两个摘要也随 LaTeX 整合包提供；原始仓库路径与 SHA256 见同目录的 `provenance.json`。各实验目录同时保存构建身份、输入清单和原始运行记录。

3.12.1 复现与图像来源

本报告在 `zjhwork` 文档与证据基础上，合入 `zufan` 的功能进展和已选插图，资料修订日期为 2026 年 11 月 6 日。实际产生测量的构建由前表单独标识，仓库合并与文档编辑不改变这些实验的身份。

原始日志、失败记录及构建清单随各实验目录保存。R5 组合验收保留原 UTC 占用审计记录，并使用同一启动环境下的单调时钟记录补充核对；性能表使用 DUT 周期。复现者可从各目录的 RESULT、合同和输入清单进入对应原始记录。

图中概念示意用于解释计算和验证流程，技术图依据源码、测试记录及测量数据绘制，终端与 GTKWave 截图保留实际观察内容。LaTeX 整合包包含正文直接引用的图像与日志，完整工程证据按本节索引在团队仓库及对应归档中查询。