第三阶段协同仿真与性能分析文档

香山昆明湖 V2 自定义向量点积指令

工程组合 0f ＋ firstdot V2 ＋原 C8　材料日期 2026 年 11 月 2 日

团队名称（待团队确认）　成员（待团队确认）

工程版本为 0f ＋ firstdot V2 ＋原 C8，初稿日期为 2026 年 11 月 2 日。

1　验证与评估目标

本阶段通过独立 NEMU 语义模型与香山 RTL 协同仿真验证指令行为，并采用等价 RVV 实现评估周期收益。工程评价同时考虑完整结果、异常、状态恢复、控制正确性、软件调用边界及硬件成本。

2　NEMU 扩展

NEMU 以 a48a11f208ff81ad765591d83271d1b339fb3861 为基点，使用 vdot 补丁 1.1.0 及 xs-16ae9dd-vdot-runtime-tval-v1 平台配置。补丁绑定 7 个变化文件，SHA256 为 6c165bf5f94ef0bfb4f894a5f06eb6d620d4a7e0e12f3b1400fa72811f5d24db。

执行过程先匹配 custom-0 编码并检查合法向量状态，再快照读取两源，逐项转换 signed int8、从零求和并写回完整 128 位结果。独立软件求和有助于与硬件乘法/归约结构交叉验证。

平台适配对齐非法指令 xTVAL 行为。固定香山中，译码已知非法与 FU 发现 VL 非法的路径具有不同 xTVAL 表现，reference 按同一架构谓词建模。对应检查仍覆盖异常码、陷阱 PC、xTVAL 及目的状态。全核实验使用已验证 reference 角色，特权验证范围以现有 M 模式记录为准。

3　差分、拒错与恢复

DiffTest 将硬件提交后的架构状态与 NEMU 对应状态比较。除正常算术结果外，本项目检查完整向量写回、向量 CSR、寄存器别名和非法状态路径。

负控对 vdot 结果的 bit100 注入错误，检验高 96 位比较是否真正生效。成功的拒错记录应呈现对应 PC/机器字、向量目的及差异位置，并以预期错误终止。随后恢复正常 reference，运行同一镜像取得正常结果，再用独立重放确认验证结构一致。

R5/G5 选择原 13 项记录与 1 项新控制诊断组成验收，原始记录重新解析后通过。全核功能矩阵包含 117 个不同用例及 124 次分片执行。新控制诊断检查 131072 字节寄存器结果。算术模型、局部 RTL、全核作业和应用矩阵的数量按其范围分别记账。

clean-02 原宿主 UTC 并发审计存在 80.119ms 表观四路重叠，旧 FAIL 记录保留。补证以同 boot/PID 单调包络完成所选审计，组合 UTC 峰 3、补项单调峰 1。系统 UTC 稳定性仍待建立，性能采用 DUT guest 周期。

4 等价 RVV 基线与测量方法

已知配置的 RVV 单次点积通过 vwmul.vv 得到宽化乘积，再切换到 e16、清零目的向量，使用 vwredsum.vs 形成 32 位总和，最后恢复入口向量状态。目的清零覆盖完整向量，宽化归约保留已清零的高位。RVV 批处理共享允许共享的配置开销。

两路径计算相同输入和完整输出，检查声明的寄存器副作用、CSR 以及缓冲区护栏。相同镜像使用相同窗口规则、数据和循环次数。正式周期按三组数据、每组四个正式窗口统计，首次及预热另存，独立重放用于一致性检查。

加速比 S = C_RVV / C_vdot。相对旧版的周期降低率 R = (C_old − C_new) / C_old。

在固定香山实现中，fence 与 CSR 读组成的测量边界经实际入队、采样、退休记录核验。每窗校验四条 CSR 指令的 PC、机器字和 ROB 身份，cycle 差与全核 tick 差对应，instret 差与实际退休/ELF 展开计数一致。绝对计数器按整数解析。原记录中的首次、预热和失败样本完整保存。

5 硬件微基准结果

下表来自 0f 同镜像对照合同，均为正式窗口均值。

场景	vdot cycles	RVV cycles	加速比
单次点积	71.000	85.250	1.200704×
依赖链 256	1857.000	5440.500	2.929725×
四路独立 batch128	221.000	678.000	3.067873×
加载/计算/存储 stream64	1127.500	1133.000	1.004878×

独立批量可以利用 O2 的连续接收能力，依赖链受到前后数据依赖约束，stream 场景还承担访存及循环开销。结果显示收益随工作负载改变。

O1→O2 的独立同镜像比较中，batch128 由 362.5 降至 221 周期，减少 39.0345%。H1 及 0f 修复分别保持各自 96 对正式窗口周期相同。阶段间比较采用各自冻结合同。

6 软件调用与 C8 结果

firstdot 以首段点积初始化累加状态，后续段按约定求和。C8 在已验证 8×32 路径中复用配置，提供普通 C 显式入口和 RVV 回退。输入为对齐的 288 字节 A||x，输出为 8 个 16 字节完整槽。

同合同 8×32 实现	完整调用 cycles
firstdot	282.25
原 C8 配置复用 vdot	273.00
本批最快合格 RVV	299.00

C8 相对 firstdot 减少 3.2772%，相对同批最快 RVV 为 1.095238×。该结果来自三数据集完整

矩阵，普通 C 验证、软件包和回接分别补齐调用、ABI、拒错、搬移与最终镜像等价资格。

原合格镜像、复制对照、SDK 接入版 BIN 均为 31440 字节，SHA 相同。PT_LOAD、48 条调用表项与 12 组输入数据一致，ELF 差异位于调试节。627 项保护输入支持复用原功能证据。后续任意新应用按实际输入生命周期和最终链接重新界定资格。

4×8 和 16×64 采用原 firstdot 入口，4×13 选择更快的 RVV。C8 普通调用接口、固定对象及最终镜像身份可由原接入记录核对。

7 面积、时序与设计成本

使用 Nangate45 Typical 1.10V/25°C，Yosys0.9、ABC1.01 及 OpenSTA2.0.17。主档周期 1ns、负载 5fF，采用固定线负载模型，另有 0.5ns、2ns 及 1fF、20fF 敏感性档。

指标	FU	完整 VFEX4 父级
标准单元面积 μm²	17,298.246	284,614.946
nominal r2r 到达 ns	1.163404	3.261218
nominal 最差 setup 裕量 ns	−0.268520	−2.393998

父级面积包含 FU 及 DIV。负裕量表明 1ns 参考目标仍有时序违例，整核 Fmax、功耗和布线后时序为待测。H1 相对 O2 独立 FU 面积降低 2.33386%，父级降低 0.137349%，同时保留部分路径退化。0f 的取消关钟修复以正确性为依据，其周期不退化与成本变化分别留档。

8 优化探索及最终取舍

探索	结果	最终处理
P1 / P1-R1 输入分离	锚点超出 1% 门槛	HOLD
P4 一拍两槽	成本原 47 项中 6 项失败	NO-GO
P4 唯一修订	47 项中 10 项失败	NO-GO
C8 分段归约	同轮观测 273.75→273 周期，锚点及 3% 收益未过	关闭该候选
P3 FP32→QKV	正常校准在限额内取得前缀，0 完整计时窗，7200 秒完整上界未闭合	暂存 HOLD

上述试验支持最终选型，正式性能表使用已获资格的稳定结果。参数扩展提供 INT16 独立单元证据，当前工程的应用演示范围为点积微基准及固定 GEMV 调用。

9 结论

本项目完成自定义指令硬件接入、独立 NEMU 扩展、分层功能验证及等价 RVV 周期分析。O2 提升独立吞吐，H1 降低结果状态成本，0f 处理 DIV 取消关钟，firstdot 与 C8 改善固定软件调用。工程通过固定源、镜像、输入及原始证据绑定实现复核，材料中如实列出失败、时序违例和验证边界。

NEMU 补丁说明 • 测量合同 • 0f 性能与成本 • 版本数据对照

10 最终版本与性能证据身份

- 资料与稳定代码发布提交为 eca41d7cd959f5f3c4f240e382919c492d1ccb96。
- 生产硬件提交为 0f12df675378556670afd0dd2153f47fcb330610。
- clean-02 EMU 的 SHA256 为 acf672eb39f836da4000b253849e3214089e9c8e5198060a57d2cc6bbd393da9。
- reference 的 SHA256 为 62b1707c52a4c323468481e0c1863b79f244d9a3fd54aeb7b7d2ecb5f01a35ca。
- C8 最终 BIN 的 SHA256 为 56805506eb98b68269c73a3645d8f75dff73b697e30dec5f93ccc4716089ad34。

本稿保留最终版本、同合同测量和各层原始证据的关系，报告中的周期收益由已有实验支持。